


Артём Седов — Aviastar — Чат-движок RAG AI Ассистента



Объединение
чата
нормализует
(sessionId,
source="telegram",
chatInput)

Начало разговора — приветственное сообщение

Проверка: не callback
(callback_query NOT exists)

Сообщение о запрете — "Вам не разрешён доступ в этот чат"

Подготовка
журнала
запрета →
Запись
запрета в
Supabase

Журнал
несанкционированного
доступа
в
chat_log

Запись нажатия кнопки в Supabase (useful = true/false)

Благодарность пользователю (если useful = true). Если useful = false — предложить обратиться к человеку.

Связь
с
записью
журнала
через
message
- 2

Категоризация
(hr / legal / general)

Структурированный
парсер вывода
— категория

Категория
в
читаемом
виде →

полное
описание



Поиск в базе знаний

База знаний Legal/HR (top-10 чанков, Supabase
pgvector)

Эмбединг
запроса
Gemini
—
векторизация
вопроса



Простая
память
(буфер
сессии)



Модель
чата
OpenRouter
(deepseek-v4-
flash)
обслуживает
все вызовы
LLM

AI-агент Legal/HR
генерирует
ответ

Системный
промпт:

- искать документ даже для простых вопросов
- отвечать только по документу
- указывать источники
- отклонять не-HR/legal темы

- отвечать на русском

Вывод агента на оценку

Скоринг RAG-ответа

Оценщик ответов LLM оценивает ответ по 5 критериям

Структурированный парсер вывода:

Схема:
hasCitations (bool),
sourceCount (num),
relevance,
specificity,
completeness,
confidence (0–1) autoFix +
retryOnFail +
continueRegula

Шаблон ответа:
compositeScore =
среднее(4-х
числовых)

compositeScore < 0,6 → ниже порога 60 %
hasCitations = false → нет источников

Чат или Telegram?

Ответ через RAG-чатбот

Маршрутизация

