


Артём Седов — Aviastar — Чат-движок RAG AI Ассистента



"Работаю над
вашим
вопросом..."

Объединение
чата
нормализует
(sessionId,
source="telegram",
chatInput)

Это
команда
/start?



сообщение != "/start"

Отправка
подтверждения:
"Работаю над
вашим
вопросом..."

Объединение
чата
нормализует
(sessionId,
source="telegram",
chatInput)

Начало разговора — приветственное сообщение

Проверка: не callback
(callback_query NOT exists)

Сообщение о запрете — "Вам не разрешён доступ в этот чат"

Подготовка
журнала
запрета →
Запись
запрета в
Supabase

Журнал
несанкционированного
доступа
в
chat_logs

Это
callback_query

—
игнорируем
(обрабатываем
в блоке
обратной
связи)

Запись нажатия кнопки в Supabase (useful = true/false)

Благодарность пользователю (если useful = true). Если useful = false — предложить обратиться к человеку.

Связь
с
записью
журнала
через
message
— 2

Категоризация
(hr / legal / general)

Структурированный
парсер вывода
— категория

Категория
в
читаемом
виде →
полное
описание

Поиск в базе знаний

База знаний Legal/HR (top-10 чанков, Supabase
pgvector)

Эмбеddинг
запроса
Gemini
—
векторизация
вопроса

Простая
память
(буфер
сессии)

Модель чата OpenRouter (deepseek-v4-flash) обслуживает все вызовы LLM

AI-агент Legal/HR генерирует ответ

Системный промпт:

- отвечать только по документам - указывать источники
- искать документы даже для простых вопросов
- отвечать только по документам
- указывать источники
- отклонять не-HR/legal темы
- отвечать на русском

Вывод агента на оценку

Скоринг RAG-ответа

Оценщик ответов LLM оценивает ответ по 5 критериям

Структурированный парсер

Вывода:



Схема:
hasCitations
(bool),
sourceCount
(num),
relevance,
specificity,
completeness,
confidence (0–
1) autoFix +
retryOnFail +
continueRegular

Шаблон
ответа:
compositeScore
=
среднее(4-
х
числовых)



compositeScore
< 0,6 → ниже
порога 60 %
hasCitations =
false → нет
источников

Чат или Telegram?

Ответ через RAG-чатбот

Маршрутизация
в Telegram

Отправка ответа с кнопками (полезно / не помогло)

Подготовка записи журнала (8
полей оценки + метаданные)

Запись
журнала
в
Supabase
(chat_logs)

Оценка ответа
пользователем

