


Артём Седов — Aviastar — Индексация документов в RAG



Фильтр: /chast-, -tk-rf, .pdf,
.doc

Подготовка
веб-
документа к
обработке

Слияние
источников
документов
(вход 0: web)

Поиск файлов и папок

Google Drive: aviastar-
sample-docs

Разделение
Google-
документов

Подготовка
Google-
документа к
обработке

Слияние
источников
документов
(вход 2: google)

Чтение локальных
документов

/home/node/.n8n-
files/docs/*
(отключено)

Подготовка
локального
документа

Слияние
источников
документов
(вход 1: local)

Удаление
дубликатов
документов
(по
document.id)



Цикл по
документам
(batch=5)



Обработка документов в цикле

Маршрутизация
документа по
источнику
(если source ==
local)



ИСТОЧНИК == local

Извлечение
локального
PDF



Подготовка
метаданных
документа



ИСТОЧНИК == web

Загрузка веб-
страницы



Извлечение
текста из
веб-
страницы



Подготовка
метаданных
документа



Очистка
содержимого
документа

Удаление
дублирующегося
содержимого
(по
metadata.documentId)

Разбиение, эмбединг и сохранение

Рекурсивный
разделитель
текста
(chunk=500,
overlap=50)

500 символов на чанк, 50
перекрытие

Стандартный
загрузчик
данных

Эмбединг чанков Gemini
(models/gemini-embedding-001)

Google Gemini text-embedding-
001 3072-мерные векторы

Векторные эмбединги

Загруженные чанки документов

Вставка в
векторное
хранилище
(Supabase
pgvector)

Таблица:
documents

Векторное поле:
embedding

Мета: documentId,
documentName,
processedDate

